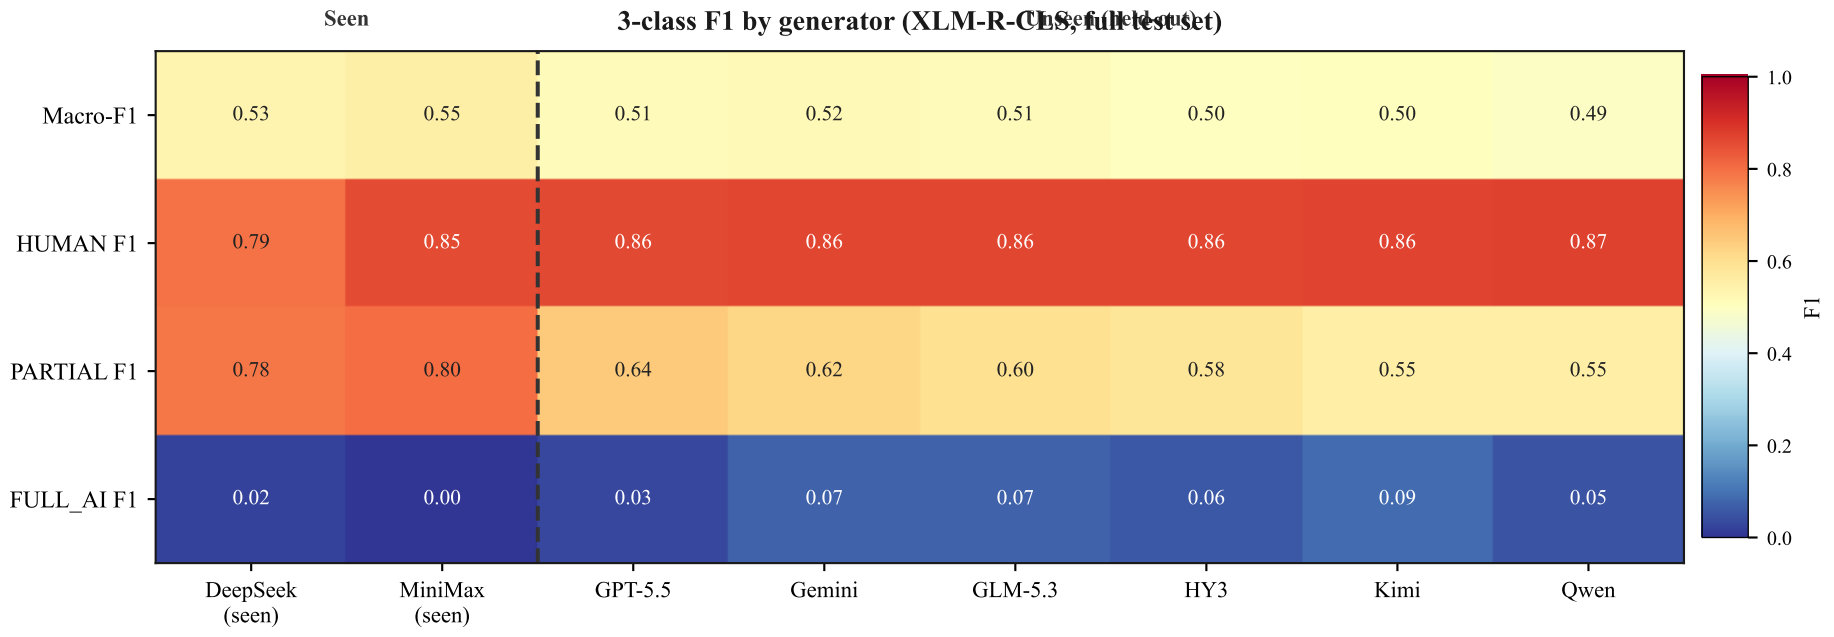
3-class F1 by generator (XLM-R-CLS, full test set)
Seen
Unseen (held-out)
Macro-F1
HUMAN F1
PARTIAL F1
FULL_AI F1
0.53
0.55
0.51
0.52
0.51
0.50
0.50
0.49
0.79
0.85
0.86
0.86
0.86
0.86
0.86
0.87
0.78
0.80
0.64
0.62
0.60
0.58
0.55
0.55
0.02
0.00
0.03
0.07
0.07
0.06
0.09
0.05
DeepSeek (seen)
MiniMax (seen)
GPT-5.5
Gemini
GLM-5.3
HY3
Kimi
Qwen
F1
1.0
0.8
0.6
0.4
0.2
0.0